

# 概率论与随机过程

授课教师：唐宏岩

# 前言

本讲义基于清华大学数学系唐宏岩老师于 2023 - 2024 学年秋季学期开设的《概率论与随机过程》课程，用于辅助同学们课后复习。

由于时间与能力所限，本讲义可能不会出现大段的文字论述（但会包含重要的定义、定理与公式等）。但是，对许多基本概念的深入理解是非常有必要的，同学们可以在浏览时检查自己是否能够回忆起课上的内容，对掌握不够扎实的地方，鼓励大家查阅参考书或在课程群提问以解决问题。

由于此为教学团队第一年尝试整理讲义，诸如格式编排、内容完整性方面可能存在许多不足，欢迎大家联系我提出宝贵的意见与建议。

曹子尧

2023 年 9 月

# 目录

前言	i
第一部分 初等概率论	1
第一章 事件的概率	2
1.1 概率的发展史	2
1.2 随机试验与事件	2
1.3 事件的运算	3
1.4 概率的几种解释	3
1.5 概率的公理化定义	3
1.6 条件概率	4
1.7 事件的独立性	5
1.8 Bayes 公式	6
第二章 随机变量	8
2.1 一维随机变量	8
2.2 离散随机变量	10
2.3 常见离散分布	11
2.4 连续随机变量	12
2.5 常见连续分布	12
2.6 随机变量的函数	14
第三章 联合分布	16
3.1 随机向量	16
3.2 离散分布	16
3.3 连续分布	17

3.4 边际分布 . . . . .	17
3.5 条件分布 . . . . .	18
3.6 独立性 . . . . .	18
3.7 随机向量的函数 . . . . .	19
<b>第四章 随机变量的数字特征</b>	<b>22</b>
4.1 期望 . . . . .	22
4.2 分位数 . . . . .	22
4.3 方差 . . . . .	23
4.4 协方差与相关系数 . . . . .	23
4.5 矩 . . . . .	24
4.6 矩母函数 . . . . .	25
4.7 条件期望 . . . . .	27
<b>第五章 不等式与极限定理</b>	<b>29</b>
5.1 概率不等式 . . . . .	29
5.2 大数定律 . . . . .	30
5.3 中心极限定理 . . . . .	31
<b>第二部分 随机过程</b>	<b>33</b>
<b>第六章 Poisson 过程</b>	<b>36</b>
6.1 基本概念 . . . . .	36

# **第一部分**

## **初等概率论**

# 第一章 事件的概率

## 1.1 概率的发展史

赌博中的 de Méré's Problem: 连续掷一个均匀六面骰 4 次, 获得至少一次 “6” 的概率为  $1 - (\frac{5}{6})^4 \approx 0.5177$ ; 而连续掷两个均匀六面骰 24 次, 获得至少一次 “对 6” 的概率为  $1 - (35/36)^{24} \approx 0.4914$ 。

Pascal 和 Fermat 的通信中使用初等数学的方法, 首创了概率论相当多的数学理论, 虽然当时没有总结成通用的定理。

Laplace 创立了采用分析方法的分析概率论。

Kolmogorov 利用测度论方法发展了现代概率理论。

## 1.2 随机试验与事件

**定义 1.1.** 概率论中的随机试验指的是符合下面两个特点的试验:

1. 不能预先确知结果
2. 可以预测所有可能的结果

**定义 1.2.** 样本空间是指一个试验的所有可能结果的集合, 常用  $\Omega$  表示。

**定义 1.3.** 事件是样本空间的一个良定义子集。

一次随机试验中, 一个事件可能发生或不发生。

下面是一些常见的事件:

1. 全事件  $\Omega$  (必然事件)
2. 空事件  $\emptyset$  (不可能事件)
3. 基本事件  $\{a\}$ , 其中  $a \in \Omega$ , 即仅包含单一试验结果的事件

## 1.3 事件的运算

由于事件是集合，因此事件之间可以进行集合之间的运算，如：

1. 余  $A^c = \Omega \setminus A$
2. 和  $A + B = A \cup B = (A^c \cap B^c)^c$
3. 差  $A - B = A \setminus B$
4. 积  $AB = A \cap B = (A^c \cup B^c)^c$

集合的 De Morgan's laws 也适用于事件： $(\bigcup_n A_n)^c = \bigcap_n A_n^c$ 。

事件的运算像集合的运算一样，可以用 Venn 图来表示。

## 1.4 概率的几种解释

对于概率这一数学概念，人们形成了几种从不同角度出发的解释：

1. 古典解释：基于等可能性的解释
2. 频率解释：基于大量重复试验的解释（频率学派采用的解释）
3. 主观解释：概率是一种对确信程度的度量（Bayes 学派采用的解释）

## 1.5 概率的公理化定义

我们用  $2^\Omega$  表示  $\Omega$  的幂集，即  $\Omega$  的所有子集组成的集合。

**定义 1.4.** 事件集类  $\mathcal{F} \subset 2^\Omega$  必须满足所谓  $\sigma$ -代数的性质：

1.  $\Omega \in \mathcal{F}$
2.  $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$ （对补运算的封闭性）
3.  $A_i \in \mathcal{F}, \forall i \in \mathbb{N}^* \Rightarrow \bigcup_{i=1}^\infty A_i \in \mathcal{F}$ （对可列并的封闭性）

**例 1.1.**  $\Omega = \{a, b, c, d\}$ ，以下是一些合法的事件集类：

1.  $\mathcal{F}_1 = 2^\Omega$
2.  $\mathcal{F}_2 = \{\Omega, \emptyset\}$
3.  $\mathcal{F}_3 = \{\Omega, \emptyset, \{a, b\}, \{c, d\}\}$

**定义 1.5.** (Kolmogorov) 概率函数  $P: \mathcal{F} \rightarrow \mathbb{R}$  是满足以下三条公理的映射：

1.  $P(A) \geq 0, \forall A \in \mathcal{F}$
2.  $P(\Omega) = 1$
3.  $A_i \in \mathcal{F}, \forall i \in \mathbb{N}^*, A_i A_j = \emptyset, \forall i \neq j \Rightarrow P(\sum_{i=1}^\infty A_i) = \sum_{i=1}^\infty P(A_i)$ （加法公理/可列可加性）

我们称  $(\Omega, \mathcal{F}, P)$  是一个概率空间。

**命题 1.1.** 关于概率空间, 有如下性质:

1.  $P(A) \leq 1, \forall A \in \mathcal{F}$
2.  $P(\emptyset) = 0$
3.  $P(A) + P(A^c) = 1$
4.  $A_i \in \mathcal{F}, \forall i \in \{1, 2, \dots, n\}, A_i A_j = \emptyset, \forall i \neq j \Rightarrow P(\sum_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$  (有限可加性)
5.  $A \subset B \Rightarrow P(A) \leq P(B)$  (我们称事件  $A$  蕴涵事件  $B$ )
6.  $P(A_1 + \dots + A_n) = \sum_{i=1}^n P(A_i) - \sum_{i_1 < i_2} P(A_{i_1} A_{i_2})$   
 $+ \dots + (-1)^{r+1} \sum_{i_1 < i_2 < \dots < i_r} P(A_{i_1} A_{i_2} \dots A_{i_r})$   
 $+ \dots + (-1)^{n+1} P(A_1 \dots A_n)$

(容斥公式)

特别地,  $P(A + B) = P(A) + P(B) - P(AB)$ 。

**例 1.2.** (配对问题)

有  $n$  个人, 每人有一顶帽子。现将所有帽子放到一起, 再随机分配给每人一顶, 考虑无人拿到自己的帽子的概率。

为此, 设事件  $A_i$  为“第  $i$  个人拿到自己的帽子”, 则  $P(A_i) = 1/n$ 。

利用容斥公式, 至少一人拿到自己帽子的概率为

$$\begin{aligned} & P(A_1 + \dots + A_n) \\ &= \sum_{i=1}^n P(A_i) - \sum_{i_1 < i_2} P(A_{i_1} A_{i_2}) \\ &+ \dots + (-1)^{r+1} \sum_{i_1 < i_2 < \dots < i_r} P(A_{i_1} A_{i_2} \dots A_{i_r}) \\ &+ \dots + (-1)^{n+1} P(A_1 \dots A_n) \end{aligned}$$

其中  $\sum_{i_1 < i_2 < \dots < i_r} P(A_{i_1} A_{i_2} \dots A_{i_r}) = \frac{(n-r)!}{n!} \binom{n}{r} = \frac{1}{r!}$ , 即  $P(A_1 + \dots + A_n) = 1 - \frac{1}{2!} + \frac{1}{3!} - \frac{1}{4!} + \dots + (-1)^{r+1} \frac{1}{r!} + \dots + (-1)^{n+1} \frac{1}{n!}$ 。

所求概率  $P_n = 1 - P(A_1 + \dots + A_n) = 1 - (1 - \frac{1}{2!} + \dots + (-1)^{n+1} \frac{1}{n!}) \rightarrow e^{-1} (n \rightarrow +\infty)$ 。

思考: 恰有  $k$  个人拿到自己的帽子的概率?

## 1.6 条件概率

**定义 1.6.** 若  $P(B) > 0$ , 定义条件概率  $P(A|B) = \frac{P(AB)}{P(B)}$ 。



通常，我们计算条件概率的方法有两种：

1. 在缩小（受限）的样本空间（要求事件  $B$  发生）上，考虑事件  $A$  发生的概率
2. 根据定义计算

一种常用的形式是  $P(AB) = P(A|B)P(B) = P(B|A)P(A)$ ，这可以视作是求解两个事件的积的概率的方法（乘法法则）。

**例 1.3.** 掷一个均匀六面骰， $\Omega = \{1, 2, 3, 4, 5, 6\}$ ,  $A = \{2, 3, 4, 5\}$ ,  $B = \{1, 3, 5\}$ ，则  $P(A) = 4/6$ ,  $P(B) = 3/6$ ,  $P(AB) = 2/6$ ,  $P(A|B) = \frac{P(AB)}{P(B)} = 2/3$ 。

**例 1.4.** 袋子中有 8 个红球和 4 个白球，无放回地取出两个球，利用组合数可知，两个都是红球的概率为  $\frac{\binom{8}{2}}{\binom{12}{2}}$ 。

用条件概率可以简化计算： $P(R_1R_2) = P(R_1)P(R_2|R_1) = \frac{8}{12} \times \frac{7}{11}$ 。

更一般地，我们有  $P(A_1A_2 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1A_2) \cdots P(A_n|A_1A_2 \cdots A_{n-1})$ ，常用于序贯发生的一系列事件的积的概率求解。

**例 1.5.** 回忆上一节的“配对问题”。我们有

$$\begin{aligned} & P(A_{i_1}A_{i_2} \cdots A_{i_r}) \\ &= P(A_{i_1})P(A_{i_2}|A_{i_1}) \cdots P(A_{i_r}|A_{i_1} \cdots A_{i_{r-1}}) \\ &= \frac{1}{n} \times \frac{1}{n-1} \times \cdots \times \frac{1}{n-(r-1)} \\ &= \frac{(n-r)!}{n!}. \end{aligned}$$

**命题 1.2.** 对于给定的事件  $B$ ， $P(\cdot|B) : \mathcal{F} \rightarrow \mathbb{R}$  是概率函数，即  $(\Omega, \mathcal{F}, P(\cdot|B))$  仍是概率空间。

对于上述命题的证明，只需验证  $P(\cdot|B)$  满足概率的三条公理即可。

这提示我们，条件概率也是一种概率，如果我们将  $P(A)$  称为观察到事件  $B$  之前  $A$  的“先验概率”，则  $P(A|B)$  就是相应的“后验概率”。

一个常见的迷思是：观测到事件  $A$  已经发生后，是否可以说事件  $A$  发生的概率  $P(A) = 1$ ？学过条件概率之后，我们知道答案是否定的，实际上是后验概率  $P(A|A) = 1$ 。

## 1.7 事件的独立性

**定义 1.7.** 若  $P(AB) = P(A)P(B)$ ，则称事件  $A, B$  相互独立。

如果  $P(B) > 0$ ，我们注意到  $A, B$  独立等价于  $P(A|B) = P(A)$ 。

**命题 1.3.** 若  $A, B$  独立, 则  $A^c, B$  独立。

**定义 1.8.** 若  $P(ABC) = P(A)P(B)P(C)$ , 且  $A, B, C$  两两独立, 则称事件  $A, B, C$  独立。

注意, 仅有  $A, B, C$  两两独立, 不能推出三者独立。

**定义 1.9.** 若对于事件列  $\{A_i\}_{i=1}^\infty$ , 任意取有限个事件  $A_{i_1}, A_{i_2}, \dots, A_{i_r}$ , 都有  $P(A_{i_1}A_{i_2}\cdots A_{i_r}) = P(A_{i_1})P(A_{i_2})\cdots P(A_{i_r})$ , 则称  $\{A_i\}_{i=1}^\infty$  相互独立。

**例 1.6.** 每周开奖的彩票, 各次中奖率均为  $10^{-5}$  且独立, 问连续十年 (520 周) 不中奖的概率? 令事件  $A_i$  为第  $i$  周不中奖, 则  $P(A_i) = 1 - 10^{-5}$ , 故  $P(A_1 \cdots A_{520}) = (1 - 10^{-5})^{520} \approx 0.9948$ 。

**定义 1.10.** 若事件  $A, B, E$  满足  $P(AB|E) = P(A|E)P(B|E)$ , 则我们称  $A, B$  关于  $E$  条件独立。

注意, 条件独立性和独立性之间没有蕴涵关系。

## 1.8 Bayes 公式

**定理 1.1.** (全概率公式)

设  $\{B_i\}$  是  $\Omega$  的一个分割, 即

1.  $\sum_i B_i = \Omega$
2.  $B_i B_j = \emptyset, \forall i \neq j$
3.  $P(B_i) > 0, \forall i$

则  $P(A) = P(\sum_i (AB_i)) = \sum_i P(AB_i) = \sum_i P(A|B_i)P(B_i)$ 。

注:  $\{B_i\}$  可以是有限集合, 或可数无穷集合。

**例 1.7.** 对于调查问卷中的敏感问题 (如 “你是否有过某病史”), 被调查者可能会有所顾虑而做出虚假的回答。为保护被调查者的隐私, 同时取得其信任, 考虑引入一个 “保护性问题”, 即不具有敏感性的问题 (如 “你是否会游泳”), 并让被调查者以抛硬币的方式, 随机抽取一个问题回答。这样, 抽到敏感问题的、确有过该病史的被调查者在回答 “是” 时也无须有病史暴露之虞。

设人群中, 敏感问题答案为 “是” 的比例为  $p$  (未知), 保护性问题答案为 “是” 的比例为  $q$  (假设已知), 则若收集到  $n$  个被调查者的结果, 其中  $k$  个为 “是”, 我们便有  $\frac{1}{2}p + \frac{1}{2}q \approx \frac{k}{n}$ , 可以据此得到  $p$  的估计。

**定理 1.2.** (Bayes 公式 / Bayes 准则)

设  $\{B_i\}$  是  $\Omega$  的一个分割, 则  $P(B_i|A) = \frac{P(B_i)P(A|B_i)}{\sum_j P(B_j)P(A|B_j)}$ 。

**例 1.8.** (假阳性悖论)

对于一种流行病,  $A$  表示一个人检查呈阳性,  $B$  表示此人确实患病。

设  $P(B) = 10^{-4}$ ,  $P(A|B) = 0.99$ ,  $P(A|B^c) = 10^{-3}$ ,

则一个检查呈阳性的人真的患病的概率仅为  $P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B)+P(A|B^c)P(B^c)} \approx 9\%$ 。

如果再次检测仍呈阳性, 且两次检测效率不变, 结果彼此独立, 则此人真的患病的概率为

$$P(B|A_1A_2) = \frac{P(A_1A_2|B)P(B)}{P(A_1A_2|B)P(B)+P(A_1A_2|B^c)P(B^c)} = \frac{P(A_1|B)P(A_2|B)P(B)}{P(A_1|B)P(A_2|B)P(B)+P(A_1|B^c)P(A_2|B^c)P(B^c)} \approx 99\%。$$

## 第二章 随机变量

### 2.1 一维随机变量

**定义 2.1.** 随机变量是样本空间上的实值函数。

注意，上述定义是不严格的。

更严谨的定义：若对于可测空间  $(\Omega, \mathcal{F})$  和函数  $X : \Omega \rightarrow \mathbb{R}$ ，有  $\forall x \in \mathbb{R}, \{\omega | X(\omega) \leq x\} \in \mathcal{F}$ ，则称  $X$  是  $(\Omega, \mathcal{F})$  上的随机变量。其中“可测空间”是指  $\mathcal{F}$  是样本空间  $\Omega$  上的  $\sigma$ -代数。此处不要求“概率空间”，即随机变量的定义并不依赖概率测度  $P$  的存在。

**例 2.1.** 下表展示了两个随机变量。其中“像集”即  $\{X(\omega) | \omega \in \Omega\}$ 。

试验	样本空间 $\Omega$	随机变量 $X$	像集
随机调查 50 人对某议题支持与否	$\Omega_1 = \{0, 1\}^{50}$	$X_1 = \text{“1”的个数}$	$\{0, 1, \dots, 50\}$
随机抽取一名北京成年市民	$\Omega_2 = \text{所有北京成年市民之集}$	$X_2 = \text{其年收入}$	$\mathbb{R}$

注意，我们经常用“ $X_1 = 20$ ”、“ $X_2 > 100000$ ”等简化的记号来表示事件。例如，前者实际上指的是  $\{\omega \in \Omega_1 | X_1(\omega) = 20\}$ 。

诸如此类的试验结果集合需是事件，这体现出前述的随机变量严谨定义的意义。事实上，如果满足该严谨定义，则对于任意可测集  $I \subset \mathbb{R}$ ，都有  $\{\omega \in \Omega | X(\omega) \in I\} \in \mathcal{F}$ 。

随机变量是试验结果的数值摘要，起到一种概括的作用。随机变量的“随机”要素来自于样本点  $\omega \in \Omega$  的随机选择。在实际应用中，随机变量常常比样本空间具有更直观的意义。

随机变量可以分为：

1. 离散型：至多可数多个取值
2. 连续型：区间型取值（非严格定义）
3. 其他

“其他”中的一个非常特殊的子类是所谓的混合型随机变量。

**定义 2.2.** 对于随机变量  $X$  和  $\mathbb{R}$  的可测子集  $I$  (例如  $I = (a, b]$ ), 令  $X^{-1}(I) = \{\omega \in \Omega | X(\omega) \in I\} \subset \Omega$  为  $I$  的原像集, 我们定义记号  $P(X \in I)$  表示 “ $X$  的取值在  $I$  中的概率”, 其值为  $P(X^{-1}(I))$ 。

例如,  $P(a < X \leq b) = P(\{\omega | X(\omega) \in (a, b]\})$ 。

**定义 2.3.**  $F_X(x) = P(X \leq x), \forall x \in \mathbb{R}$  称为随机变量  $X$  的累积分布函数 (Cumulative Distribution Function, CDF)。下标  $X$  在无歧义时可省略。

我们有  $P(a < X \leq b) = F(b) - F(a)$ 。

**例 2.2.** 令  $X$  表示掷两个均匀六面骰所得的点数和, 则  $X$  的分布表 (详见 2.2 节) 为

$X$	2	3	4	5	6	7	8	9	10	11	12
$P$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

相应的 CDF 见图 2.1。




图 2.1:  $X$  的 CDF 图象

注: 由于软件限制, 各个阶跃点的绘制方式不太规范, 实际上从其左侧逼近应该为一个空圈, 例如  $F(3) = 3/36$  而不是  $1/36$ 。另外,  $\forall x < 2, F(x) = 0; \forall x \geq 12, F(x) = 1$ 。

**命题 2.1.** CDF 的性质:

1.  $F$  单调递增 (未必严格单调递增)
2.  $\lim_{x \rightarrow +\infty} F(x) = 1, \lim_{x \rightarrow -\infty} F(x) = 0$
3.  $F$  右连续

可以证明, 上述三条性质是任意函数  $F: \mathbb{R} \rightarrow \mathbb{R}$  成为 CDF 的充要条件。

思考: 如果我们将 CDF 的定义改为  $P(X < x)$ , 上述性质会如何变化?

**命题 2.2.** 若  $X, Y$  为随机变量, 则  $aX + bY, XY, X/Y$  (需  $Y \neq 0$ ) 都是随机变量。一般地, 若  $g$  为可测函数, 则  $g(X, Y)$  是随机变量。

**定义 2.4.** 设  $X_1, X_2$  的 CDF 分别为  $F_1, F_2$ , 我们称  $X_1$  与  $X_2$  同分布, 若  $\forall x \in \mathbb{R}, F_1(x) = F_2(x)$ 。

**命题 2.3.** 随机变量  $X_1$  与  $X_2$  同分布的一个充要条件是  $\forall$  可测集  $I \subset \mathbb{R}, P(X_1 \in I) = P(X_2 \in I)$ 。

注意, 同分布不等价于“同变量”, 即两个同分布的变量的取值不一定恒等。

**例 2.3.** 掷一次硬币,  $X$  表示正面向上次数,  $Y$  表示反面向上次数, 显然  $X$  与  $Y$  同分布, 但取值不等。

## 2.2 离散随机变量

**定义 2.5.** 离散随机变量  $X$  的概率质量函数 (Probability Mass Function, PMF)  $f$  是指该随机变量取各个可能值的概率, 即  $f(x) = P(X = x), \forall x \in \mathbb{R}$ 。可以用分布表的形式展示各个可能取值与概率的对应关系。

**命题 2.4.** 如果离散随机变量  $X$  的所有可能取值为  $\{x_i\}$ , 则  $X$  的 PMF 具有如下性质:

1.  $f(x_i) = p_i \geq 0, \forall i$
2.  $\sum_i p_i = 1$
3.  $F(x) = \sum_{x_i \leq x} f(x_i)$

**定义 2.6.** 离散随机变量  $X$  的期望定义为  $E(X) = \sum_i x_i p_i$ 。

我们称  $X$  的期望存在, 当且仅当  $\sum_i |x_i| p_i < +\infty$ 。

当期望存在时, 其方差定义为  $\text{Var}(X) = \sum_i (x_i - E(X))^2 p_i = E((X - E(X))^2) = E(X^2) - E^2(X)$ 。

当方差有限时, 称其算术平方根为  $X$  的标准差, 记作  $\text{SD}(X)$ 。

注意, 通常我们所说的一个随机变量的均值指的就是期望。

标准化指的是对  $X$  作线性变换  $\frac{X - \mu}{\sigma}$ , 其中  $\mu$  和  $\sigma$  分别为  $X$  的期望和标准差, 得到均值为 0, 标准差为 1 的随机变量。

对于可测函数  $g$ ,  $g(X)$  也是随机变量, 其期望  $E(g(X)) = \sum_i g(x_i) p_i$ 。

期望反映了随机变量的集中趋势, 而方差反映了其分散程度。

## 2.3 常见离散分布

**定义 2.7.** 称一个随机变量  $X$  服从 *Bernoulli* 分布, 若  $\exists p \in (0, 1)$ ,  $X$  的取值集合为  $\{0, 1\}$ , 且  $P(X = 1) = p, P(X = 0) = 1 - p$ . 记作  $X \sim B(p)$ .

$B(p)$  中的  $p$  称为该 *Bernoulli* 分布的参数。后续介绍的其他分布同理。

我们常将两种取值分别称为“成功”和“失败”。

计算可得, 若  $X \sim B(p)$ , 则  $E(X) = p, \text{Var}(X) = p(1 - p)$ 。

**定义 2.8.** 称一个随机变量  $X$  服从二项分布, 若  $\exists N \in \mathbb{N}^*, p \in (0, 1)$ ,  $X$  的取值集合为  $\{0, 1, \dots, N\}$ , 且  $P(X = k) = \binom{N}{k} p^k (1 - p)^{N-k} (k \in \{0, 1, \dots, N\})$ . 记作  $X \sim B(N, p)$ 。

我们常将  $k$  理解为“ $N$  次独立 *Bernoulli* 试验中的成功次数”。

计算可得, 若  $X \sim B(N, p)$ , 则  $E(X) = Np, \text{Var}(X) = Np(1 - p)$ 。

**定义 2.9.** 称一个随机变量  $X$  服从 *Poisson* 分布, 若  $\exists \lambda > 0$ ,  $X$  的取值集合为  $\mathbb{N}$ , 且  $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} (k \in \mathbb{N})$ . 记作  $X \sim P(\lambda)$ 。

计算可得, 若  $X \sim P(\lambda)$ , 则  $E(X) = \lambda, \text{Var}(X) = \lambda$ 。

对 *Poisson* 分布的一种常见理解是“一段时间内某个小概率事件发生的次数”所服从的分布。例如, 观察时间  $(0, 1]$  内某路口的交通事故数  $X$ , 将  $(0, 1]$  区间等分成  $n$  个小区间, 即  $l_i = (\frac{i-1}{n}, \frac{i}{n}] (i = 1, 2, \dots, n)$ 。考虑到  $n$  很大时, 每个区间的长度很小, 我们作如下假设:

1. 每段区间内, 至多发生一次事故
2.  $l_i$  上发生一次事故的概率与区间长度  $(1/n)$  成正比, 为  $p = \lambda/n$
3. 各区间内是否发生事故彼此独立

则  $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \rightarrow \frac{\lambda^k e^{-\lambda}}{k!} (n \rightarrow +\infty)$ , 即  $X \sim P(\lambda)$ 。

**例 2.4.** 设某医院平均每天出生婴儿数为  $\lambda$ , 则接下来  $t$  天内出生婴儿数服从参数为  $t\lambda$  的 *Poisson* 分布。

对于一般的二项分布  $X \sim B(N, p)$ , 若  $p$  很小,  $N$  很大, 而  $\lambda = Np$  不太大, 则近似有  $X \sim P(\lambda)$ , 且近似误差不超过  $\min\{p, Np^2\}$ 。

进一步, 若  $N$  次 *Bernoulli* 试验并非严格独立, 但满足弱相依条件, 则 *Poisson* 分布仍为一种较好的近似。

**例 2.5.** (配对问题)

$A_i$  表示第  $i$  个人拿到自己的帽子, 则  $P(A_i) = 1/n, P(A_i | A_j) = \frac{1}{n-1} (j \neq i)$ , 当  $n$  很大时,  $1/n$

和  $\frac{1}{n-1}$  很接近, 可以认为满足弱相依条件。

记  $X$  为拿到自己帽子的人数, 则  $X$  近似服从参数为  $\lambda = np = n \cdot \frac{1}{n} = 1$  的 Poisson 分布, 即  $P(X = k) \approx \frac{e^{-1}}{k!}$ 。

我们用常规做法检查这种近似是否合理。首先考虑指定的某  $k$  人, 记事件  $E$  表示这  $k$  人拿到自己的帽子, 事件  $F$  表示其余  $(n - k)$  人未拿到自己的帽子, 则  $P(EF) = P(E)P(F|E) = \frac{(n-k)!}{n!} \cdot P_{n-k}$ , 其中  $P_{n-k}$  为  $(n - k)$  人随机拿帽子时无人拿对的概率。那么我们有  $P(X = k) = \binom{n}{k} P(EF) = \frac{1}{k!} P_{n-k} \rightarrow \frac{e^{-1}}{k!} (n \rightarrow +\infty)$ 。这说明前述的近似是较好的。

## 2.4 连续随机变量

**定义 2.10.** 对随机变量  $X$ , 若存在  $f: \mathbb{R} \rightarrow [0, +\infty)$ , 使得  $\forall$  可测集  $I \subset \mathbb{R}$ , 都有  $P(X \in I) = \int_I f(x)dx$ , 则称  $X$  为连续型随机变量,  $f$  称为其概率密度函数 (Probability Density Function, PDF)。

**命题 2.5.** 连续随机变量  $X$  的 PDF 具有如下性质:

1.  $\int_{-\infty}^{+\infty} f(x)dx \equiv 1$
2.  $P(a < X \leq b) = \int_a^b f(x)dx = P(a \leq X \leq b) = P(a \leq X < b) = P(a < X < b)$
3.  $P(X = a) \equiv 0, \forall a \in \mathbb{R}$
4. 若  $f$  在  $x_0$  处连续, 则  $P(x_0 - \delta < X < x_0 + \delta) = \int_{x_0 - \delta}^{x_0 + \delta} f(t)dt \approx f(x_0) \cdot 2\delta$
5.  $F(x) = \int_{-\infty}^x f(t)dt$  连续, 且若  $f$  在  $x$  处连续, 有  $F'(x) = f(x)$
6. PDF 若存在, 则不唯一 (可以修改其在任意零测集上的值, 得到不同的 PDF)

**定义 2.11.** 连续随机变量  $X$  的期望定义为  $E(X) = \int_{-\infty}^{+\infty} xf(x)dx$ 。

我们称  $X$  的期望存在, 当且仅当  $\int_{-\infty}^{+\infty} |x|f(x)dx < +\infty$ 。

当期望存在时, 其方差定义为  $\text{Var}(X) = \int_{-\infty}^{+\infty} (x - E(x))^2 f(x)dx = E((X - E(X))^2) = E(X^2) - E^2(X)$ 。

当方差有限时, 称其算术平方根为  $X$  的标准差, 记作  $\text{SD}(X)$ 。

对于可测函数  $g$ ,  $g(X)$  也是随机变量, 其期望  $E(g(X)) = \int_{-\infty}^{+\infty} g(x)f(x)dx$ 。

## 2.5 常见连续分布

**定义 2.12.** 称一个连续型随机变量  $X$  服从均匀分布, 若其 PDF 为  $f(x) = \frac{1}{b-a}(x \in (a, b))$ ,  $f$  在其余各处取 0。记作  $X \sim U(a, b)$ 。



我们常将  $X \sim U(0, 1)$  称为随机数。

计算可得, 若  $X \sim U(a, b)$ , 则  $E(X) = \frac{a+b}{2}$ ,  $\text{Var}(X) = \frac{(b-a)^2}{12}$ 。

**定义 2.13.** 称一个连续型随机变量  $X$  服从正态分布, 若其 PDF 为  $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$  ( $\sigma > 0$ )。记作  $X \sim N(\mu, \sigma^2)$ 。

计算可得, 若  $X \sim N(\mu, \sigma^2)$ , 则  $E(X) = \mu$ ,  $\text{Var}(X) = \sigma^2$ 。

著名的“经验法则”见图 2.2。



图 2.2: 经验法则

$X \sim N(\mu, \sigma^2)$  的充要条件是  $Y = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。我们将  $N(0, 1)$  称为标准正态分布。

**定义 2.14.** 称一个连续型随机变量  $X$  服从指数分布, 若其 PDF 为  $f(x) = \lambda e^{-\lambda x}$  ( $\lambda > 0, x > 0$ ),  $f$  在其余各处取 0。记作  $X \sim \text{Exp}(\lambda)$ 。

指数分布常用于刻画等待时间、寿命等。

计算可得, 若  $X \sim \text{Exp}(\lambda)$ , 则  $E(X) = 1/\lambda$ ,  $\text{Var}(X) = 1/\lambda^2$ 。

指数分布有另一种符号约定, 以  $\beta = 1/\lambda$  为参数, 一些数学软件可能采用此种约定。

指数分布的 CDF 为  $F(x) = 1 - e^{-\lambda x}$  ( $x > 0$ ), 所谓的“尾概率”为  $P(X > x) = 1 - F(x) = e^{-\lambda x}$  ( $x > 0$ )。

**例 2.6.** 设某医院平均每天出生婴儿数为  $\lambda$ ，现在观察到一名婴儿出生，则接下来  $t$  天内有婴儿出生的概率为  $P(X \leq t)$ ，其中  $X$  表示到下一个婴儿出生所需等待的时间。

记  $N(t)$  为  $t$  天内出生婴儿数，我们已经知道  $N(t) \sim P(t\lambda)$ ，则  $P(X > t) = P(N(t) = 0) = e^{-\lambda t}$ ，故  $P(X \leq t) = 1 - e^{-\lambda t}$ 。我们发现  $X$  服从参数为  $\lambda$  的指数分布。

我们从另一个角度理解指数分布。

首先引入失效率或危险率的概念。设  $X$  为连续型随机变量（表示某种零件的寿命），其 CDF 为  $F(x)$ ，且  $F(0) = 0$ 。考虑条件概率  $P(x < X < x + dx | X > x) = \frac{P(x < X < x + dx)}{P(X > x)} = \frac{F(x+dx) - F(x)}{1 - F(x)} \approx \frac{F'(x)}{1 - F(x)} dx$ ，即“年龄”为  $x$  的零件不能继续工作的条件概率密度为  $\frac{F'(x)}{1 - F(x)}$ ，我们称其为瞬时失效率  $\lambda(x)$ ，则  $F(x) = 1 - e^{-\int_0^x \lambda(t) dt}$ 。

在“无老化”假设下，即  $\lambda(t) \equiv \lambda$  不随时间变化，则  $F(x) = 1 - e^{-\lambda x} (x > 0)$ ， $X$  服从指数分布。

指数分布有所谓“无记忆性”： $P(X > t+s | X > s) = \frac{P(X > t+s)}{P(X > s)} = e^{-\lambda t} = P(X > t) (t, s > 0)$ 。

“无老化”假设并不总是成立。为此，我们可以进行一定程度的改进，例如令  $\lambda(x) = \alpha \frac{x^{\alpha-1}}{\beta^\alpha} (x > 0, \alpha, \beta > 0 \text{ 为常数})$ ，则  $F(x) = 1 - e^{-(\frac{x}{\beta})^\alpha} (x > 0)$ ，称之为 Weibull 分布。当  $\alpha = 1$  时，Weibull 分布退化为参数为  $1/\beta$  的指数分布。

总览至此我们介绍过的各个分布的参数，可以将其大致分为以下几类：

1. 位置参数：决定了分布平移到的位置，通常在 PMF/PDF 中体现为  $f(x) = g(x - \cdot)$  的形式，如正态分布的参数  $\mu$
2. 尺度参数：决定了分布伸缩的程度，通常在 PMF/PDF 中体现为  $f(x) = g(\frac{x}{\cdot})$  的形式，如正态分布的参数  $\sigma$ 、Weibull 分布的参数  $\beta$
3. 形状参数：决定了分布的形状，如 Weibull 分布的参数  $\alpha$

## 2.6 随机变量的函数

对于随机变量  $X$  和可测函数  $g$ ， $Y = g(X)$  也是随机变量。特别地，若  $X$  为离散型随机变量，则  $Y$  也离散。但若  $X$  为连续型随机变量， $Y$  未必连续。

**例 2.7.**  $X \sim \text{Exp}(\lambda)$ ， $Y = \begin{cases} 0, & X \leq t_0, \\ 1, & X > t_0, \end{cases}$  其中  $t_0 > 0$  为常数，则  $Y \sim B(e^{-\lambda t_0})$ 。

**例 2.8.** 设  $X$  为连续型随机变量，PDF 为  $f(x)$ ，考虑  $Y = X^2$ 。

从 CDF 入手， $\forall y > 0, P(Y \leq y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} f(x) dx$ ，我们有  $Y$  的 PDF 为  $l(y) = \frac{d}{dy} P(Y \leq y) = \frac{1}{2\sqrt{y}} (f(\sqrt{y}) + f(-\sqrt{y})) (y > 0)$ 。

特别地，若  $X \sim N(0, 1)$ ，称  $Y$  服从自由度为 1 的  $\chi^2$ -分布，读作“卡方分布”。

若  $Y = g(X)$  为随机变量，我们可以计算  $Y$  的分布如下：

- $P(Y = y) = P(g(X) = y) = P(X \in g^{-1}(y))$
- $P(Y \leq y) = P(g(X) \leq y) = P(X \in g^{-1}((-\infty, y]))$

## 第三章 联合分布

### 3.1 随机向量

**定义 3.1.** 称  $(X_1, X_2, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$  为  $(n \text{ 维})$  随机向量, 若  $\{X_i\}_{i=1}^n$  均为随机变量。

**定义 3.2.**  $n$  维随机向量的 (联合) (累积) 分布函数 (CDF) 定义为  $F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n), \forall (x_1, \dots, x_n) \in \mathbb{R}^n$ 。

对于  $n = 2$  (二元分布) 的情形, 我们常用  $(X, Y)$  来表示随机向量, 对应的 CDF 为  $F(x, y)$ 。

### 3.2 离散分布

**定义 3.3.** 称  $n$  维随机向量  $(X_1, \dots, X_n)$  是离散的, 当且仅当  $\{X_i\}_{i=1}^n$  均为离散随机变量。

离散随机向量  $(X_1, \dots, X_n)$  的 (联合) 概率质量函数 (PMF) 定义为  $f(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n), \forall (x_1, \dots, x_n) \in \mathbb{R}^n$ 。

**命题 3.1.** 离散随机向量  $(X_1, \dots, X_n)$  的 PMF 具有如下性质:

1.  $f(x_1, \dots, x_n) \geq 0, \forall (x_1, \dots, x_n) \in \mathbb{R}^n$
2.  $\sum_{x_i \in \{X_i(\omega) | \omega \in \Omega\}, \forall i \in \{1, \dots, n\}} f(x_1, \dots, x_n) \equiv 1$

注意第 2 条性质中求和的项数为至多可数, 原因是有限个至多可数集的笛卡尔积仍是至多可数集。

**例 3.1.** 设  $\{B_i\}_{i=1}^n$  为  $\Omega$  的一个分割 (分割的定义见 1.8 节),  $P(B_i) = p_i \geq 0, \forall i \in \{1, \dots, n\}$ ,  $\sum_{i=1}^n p_i = 1$ 。

进行  $N$  次独立试验, 设  $\forall i \in \{1, \dots, n\}$ , 有  $X_i$  个试验结果落在  $B_i$  中, 则若  $k_1 + \dots + k_n = N$ , 其中  $k_i$  均为非负整数, 我们有  $P(X_1 = k_1, \dots, X_n = k_n) = \binom{N}{k_1, \dots, k_n} p_1^{k_1} \dots p_n^{k_n}$ 。其中  $\binom{N}{k_1, \dots, k_n} = \frac{N!}{k_1! \dots k_n!}$  为多项式  $(a_1 + \dots + a_n)^N$  中  $a_1^{k_1} \dots a_n^{k_n}$  项的系数。

我们称  $(X_1, \dots, X_n)$  服从多项分布。

### 3.3 连续分布

**定义 3.4.** 对  $n$  维随机向量  $(X_1, \dots, X_n)$ , 若存在  $f: \mathbb{R}^n \rightarrow [0, +\infty)$ , 使得  $\forall$  可测集  $Q \subset \mathbb{R}^n$ , 都有  $P((X_1, \dots, X_n) \in Q) = \int_Q f(x_1, \dots, x_n) dx_1 \cdots dx_n$ , 则称  $(X_1, \dots, X_n)$  为连续型随机向量,  $f$  称为其 (联合) 概率密度函数 (PDF)。

**命题 3.2.** 连续随机向量  $(X_1, \dots, X_n)$  的 PDF 具有如下性质:

1.  $\int_{\mathbb{R}^n} f(x_1, \dots, x_n) dx_1 \cdots dx_n \equiv 1$
2. 以  $n=2$  为例,  $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(t, s) ds dt$ ,  $f(a, b) = \frac{\partial^2 F}{\partial x \partial y}(a, b)$ , a.e.

其中 a.e. 表示 “almost everywhere”。

**例 3.2.** 矩形域上的均匀分布的 PDF:  $f(x, y) = \begin{cases} \frac{1}{(b-a)(d-c)}, & (x, y) \in (a, b) \times (c, d), \\ 0, & \text{其他.} \end{cases}$

**例 3.3.** 二元正态分布  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$  的 PDF:

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2} \frac{1}{\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}((\frac{x-\mu_1}{\sigma_1})^2 + (\frac{y-\mu_2}{\sigma_2})^2 - 2\rho\frac{x-\mu_1}{\sigma_1}\frac{y-\mu_2}{\sigma_2})}, \forall (x, y) \in \mathbb{R}^2, \sigma_1, \sigma_2 > 0, |\rho| < 1.$$

令  $\mathbf{x} = \begin{bmatrix} \frac{x-\mu_1}{\sigma_1} \\ \frac{y-\mu_2}{\sigma_2} \end{bmatrix}$ ,  $W = \frac{1}{1-\rho^2} \begin{bmatrix} 1 & -\rho \\ -\rho & 1 \end{bmatrix}$ ,  $W = A^T A$  为正定矩阵  $W$  的 Cholesky 分解, 则  $-\frac{1}{2(1-\rho^2)}((\frac{x-\mu_1}{\sigma_1})^2 + (\frac{y-\mu_2}{\sigma_2})^2 - 2\rho\frac{x-\mu_1}{\sigma_1}\frac{y-\mu_2}{\sigma_2}) = -\frac{1}{2}\mathbf{x}^T W \mathbf{x} = -\frac{1}{2}\mathbf{x}^T A^T A \mathbf{x} = -\frac{1}{2}(A\mathbf{x})^T (A\mathbf{x})$ .

上述 Cholesky 分解的结果为  $A = \frac{1}{\sqrt{1-\rho^2}} \begin{bmatrix} 1 & -\rho \\ 0 & \pm\sqrt{1-\rho^2} \end{bmatrix}$  或  $A = \frac{1}{\sqrt{1-\rho^2}} \begin{bmatrix} -1 & \rho \\ 0 & \pm\sqrt{1-\rho^2} \end{bmatrix}$ 。

### 3.4 边际分布

对  $n$  维随机向量  $(X_1, \dots, X_n)$ , 称  $F_i(x) = P(X_i \leq x) = P(X_i \leq x, -\infty < X_j < +\infty, \forall j \neq i)$  为  $X_i$  的边际分布。

例如, 若  $n=2$ , 随机向量  $(X, Y)$  有 CDF  $F(x, y)$ , 则  $X$  的边际分布为  $F_X(x) = P(X \leq x) = P(X \leq x, Y \in \mathbb{R}) = \lim_{y \rightarrow +\infty} P(X \leq x, -\infty < Y \leq y) = \lim_{y \rightarrow +\infty} F(x, y)$ 。

若  $n=3$ , 随机向量  $(X, Y, Z)$  有 CDF  $F(x, y, z)$ , 则  $F_X(x) = \lim_{y, z \rightarrow +\infty} F(x, y, z)$ , 而  $(X, Y)$  的边际分布为  $F_{X,Y}(x, y) = P(X \leq x, Y \leq y) = P(X \leq x, Y \leq y, -\infty < Z < +\infty) = \lim_{z \rightarrow +\infty} F(x, y, z)$ 。

**例 3.4.** 设二维随机向量  $(X, Y)$  的 CDF 为  $F(x, y)$ , 则  $\forall a, b \in \mathbb{R}, P(X > a, Y > b) = 1 - F_X(a) - F_Y(b) + F(a, b)$ 。

对于离散型随机向量, 以  $n = 2$  为例, 定义边际 PMF 为  $P(X = x) = \sum_y P(X = x, Y = y)$ 。

对于连续型随机向量, 以  $n = 2$  为例, 设联合 PDF 为  $f(x, y)$ , 则  $F_X(x) = P(X \leq x, Y \in \mathbb{R}) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(t, s) ds dt$ , 则  $X$  的边际 PDF 为  $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$ 。

**例 3.5.**  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$ , 即  $X \sim N(\mu_1, \sigma_1^2)$ 。同理  $Y \sim N(\mu_2, \sigma_2^2)$ 。

### 3.5 条件分布

以  $n = 2$  为例说明条件分布的概念, 考虑随机向量  $(X, Y)$ 。

对于离散型随机向量, 设联合 PMF 为  $P(X = a_i, Y = b_j) = p_{ij} \geq 0, \sum_{i,j} p_{ij} \equiv 1$ , 则在  $Y = b_j$  条件下的  $X$  的条件 PMF 为  $P(X = a_i | Y = b_j) = \frac{P(X=a_i, Y=b_j)}{P(Y=b_j)} = \frac{p_{ij}}{\sum_k p_{kj}}$ 。条件 PMF 满足  $\sum_i P(X = a_i | Y = b_j) \equiv 1, \forall j$ 。

对于连续型随机向量, 设联合 PDF 为  $f(x, y)$ , 首先考虑条件概率  $P(X \leq x | y \leq Y \leq y + dy) = \frac{P(X \leq x, y \leq Y \leq y + dy)}{P(y \leq Y \leq y + dy)} = \frac{\int_{-\infty}^x \int_y^{y+dy} f(t, s) ds dt}{\int_y^{y+dy} f_Y(s) ds}$ , 对  $x$  求导得  $X$  在  $y \leq Y \leq y + dy$  条件下的条件 PDF 为  $\frac{\int_y^{y+dy} f(x, s) ds}{\int_y^{y+dy} f_Y(s) ds} \rightarrow \frac{f(x, y)}{f_Y(y)} (dy \rightarrow 0)$ 。

**定义 3.5.** 对于连续型随机向量  $(X, Y)$ , 设联合 PDF 为  $f(x, y)$ , 若  $f_Y(y) > 0$ , 则称  $X$  在  $Y = y$  条件下的条件 PDF 为  $f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$ 。

可以验证  $f_{X|Y}(x|y)$  满足 PDF 的各性质。

相应的条件 CDF 为  $F_{X|Y}(a|y) = P(X \leq a | Y = y) = \int_{-\infty}^a f_{X|Y}(x|y) dx$ 。

我们熟知的各个定理均有适用于连续型随机向量的版本:

1.  $f(x, y) = f_{X|Y}(x|y)f_Y(y) = f_{Y|X}(y|x)f_X(x)$  (乘法法则)
2.  $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \int_{-\infty}^{+\infty} f_{X|Y}(x|y)f_Y(y) dy$  (全概率公式)
3.  $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{f_{X|Y}(x|y)f_Y(y)}{\int_{-\infty}^{+\infty} f_{X|Y}(x|y)f_Y(y) dy}$  (Bayes 公式)

**例 3.6.**  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{1}{\sqrt{2\pi}\sigma_2} \frac{1}{\sqrt{1-\rho^2}} e^{-\frac{(y-(\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x-\mu_1)))^2}{2(1-\rho^2)\sigma_2^2}}$ , 即  $Y|X = x \sim N(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x - \mu_1), (1 - \rho^2)\sigma_2^2)$ 。

### 3.6 独立性

**定义 3.6.** 设二维随机向量  $(X, Y)$  的 CDF 为  $F(x, y)$ , 若  $F(x, y) = F_X(x)F_Y(y), \forall x, y \in \mathbb{R}$ , 则称  $X, Y$  相互独立。

可以证明, 对于二维离散型 (或连续型) 随机向量  $(X, Y)$ ,  $X, Y$  相互独立的充要条件是  $f(x, y) = f_X(x)f_Y(y), \forall x, y \in \mathbb{R}$ , 其中  $f(x, y)$  为联合 PMF (或 PDF)。

**定义 3.7.** 设  $n$  维随机向量  $(X_1, \dots, X_n)$  的 CDF 为  $F(x_1, \dots, x_n)$ , 若  $F(x_1, \dots, x_n) = F_1(x_1) \cdots F_n(x_n), \forall x_1, \dots, x_n \in \mathbb{R}$ , 则称  $X_1, \dots, X_n$  相互独立。

可以证明, 对于  $n$  维离散型 (或连续型) 随机向量  $(X_1, \dots, X_n)$ ,  $X_1, \dots, X_n$  相互独立的充要条件是  $f(x_1, \dots, x_n) = f_1(x_1) \cdots f_n(x_n), \forall x_1, \dots, x_n \in \mathbb{R}$ , 其中  $f(x_1, \dots, x_n)$  为联合 PMF (或 PDF)。

**定理 3.1.**

1. 若  $X_1, \dots, X_n$  相互独立, 则  $\forall m \in \{1, \dots, n-1\}$ , 可测函数  $g_1, g_2$ , 有  $Y_1 = g_1(X_1, \dots, X_m)$  与  $Y_2 = g_2(X_{m+1}, \dots, X_n)$  相互独立。
2. 若  $n$  维连续型随机向量  $(X_1, \dots, X_n)$  的联合 PDF 满足

$$f(x_1, \dots, x_n) = g_1(x_1) \cdots g_n(x_n), \forall x_1, \dots, x_n \in \mathbb{R},$$

其中  $g_i: \mathbb{R} \rightarrow [0, +\infty), \forall i \in \{1, \dots, n\}$ , 则  $X_1, \dots, X_n$  相互独立, 且  $X_i$  的边际 PDF  $f_i$  与  $g_i$  相差常数因子,  $\forall i \in \{1, \dots, n\}$ 。

**例 3.7.** 设  $(X, Y)$  服从如图 3.1 的三角形域  $D$  上的均匀分布, 即  $f(x, y) = \begin{cases} c, & (x, y) \in D, \\ 0, & \text{其他,} \end{cases}$  则  $X, Y$  不独立。




图 3.1: 三角形域上的均匀分布

## 3.7 随机向量的函数

本节中, 我们考虑给定随机向量  $(X_1, \dots, X_n)$  和可测函数  $g$ , 如何求  $Y = g(X_1, \dots, X_n)$  的分布。

首先介绍“直接法”。

**例 3.8.**  $X_i \sim B(n_i, p) (i = 1, 2)$  独立,  $Y = X_1 + X_2$ , 则  $\forall k \in \{0, 1, \dots, n_1 + n_2\}$ ,

$$\begin{aligned}
 P(Y = k) &= P(X_1 + X_2 = k) \\
 &= \sum_{k_1=0}^k P(X_1 = k_1, X_2 = k - k_1) \\
 &= \sum_{k_1=0}^k P(X_1 = k_1)P(X_2 = k - k_1) \\
 &= \sum_{k_1=0}^k \binom{n_1}{k_1} p^{k_1} (1-p)^{n_1-k_1} \binom{n_2}{k-k_1} p^{k-k_1} (1-p)^{n_2-(k-k_1)} \\
 &= \left( \sum_{k_1=0}^k \binom{n_1}{k_1} \binom{n_2}{k-k_1} \right) p^k (1-p)^{n_1+n_2-k} \\
 &= \binom{n_1+n_2}{k} p^k (1-p)^{n_1+n_2-k}
 \end{aligned}$$

因此  $Y \sim B(n_1 + n_2, p)$ 。

**例 3.9.** 随机向量  $(X_1, X_2)$  有联合 PDF  $f(x_1, x_2)$ , 且  $X_1 > 0$ , 考虑  $Y = X_2/X_1$ , 有  $\forall y \in \mathbb{R}, P(Y \leq y) = P(\frac{X_2}{X_1} \leq y) = P(X_2 \leq X_1 y) = \int_D f(x_1, x_2) dx_1 dx_2 = \int_0^{+\infty} \int_{-\infty}^{yx_1} f(x_1, x_2) dx_2 dx_1$ , 作  $x_2 = x_1 t$  换元得  $P(Y \leq y) = \int_0^{+\infty} \int_{-\infty}^y f(x_1, x_1 t) x_1 dt dx_1$ , 故  $Y$  的 PDF 为  $l(y) = \int_0^{+\infty} x_1 f(x_1, yx_1) dx_1$ 。



图 3.2: 区域  $D$  的范围, 其中边界线的斜率为  $y$

接下来介绍“密度函数变换法”。

设随机向量  $(X_1, X_2)$  有联合 PDF  $f(x_1, x_2)$ , 且有可逆可微的映射关系  $\begin{cases} Y_1 = g_1(X_1, X_2) \\ Y_2 = g_2(X_1, X_2) \end{cases}$ ,

据此解出逆映射  $\begin{cases} X_1 = h_1(Y_1, Y_2) \\ X_2 = h_2(Y_1, Y_2) \end{cases}$ , 则对于任意可测集  $A$ , 若  $(h_1, h_2)$  将  $A$  映射到集合  $B$ , 则



由可逆性可知  $B$  在  $(g_1, g_2)$  的映射下的值域为  $A$ 。因此我们有  $P((Y_1, Y_2) \in A) = P((X_1, X_2) \in B) = \int_B f(x_1, x_2) dx_1 dx_2 = \int_A f(h_1(y_1, y_2), h_2(y_1, y_2)) |J| dy_1 dy_2$ , 其中  $J$  为 Jacobi 行列式  $\det \begin{bmatrix} \frac{\partial h_1}{\partial y_1} & \frac{\partial h_1}{\partial y_2} \\ \frac{\partial h_2}{\partial y_1} & \frac{\partial h_2}{\partial y_2} \end{bmatrix}$ , 因此  $(Y_1, Y_2)$  的联合 PDF 为  $l(y_1, y_2) = f(h_1(y_1, y_2), h_2(y_1, y_2)) |J|$ 。

**例 3.10.** 随机向量  $(X_1, X_2)$  有联合 PDF  $f(x_1, x_2)$ , 为求  $Y = X_1 + X_2$  的 PDF, 引入  $Z = X_1$ , 则  $\begin{cases} X_1 = Z \\ X_2 = Y - Z \end{cases}$ , Jacobi 行列式为  $\det \begin{bmatrix} 0 & 1 \\ 1 & -1 \end{bmatrix} = -1$ , 故  $(Y, Z)$  的联合 PDF 为  $f(z, y - z) | -1 | = f(z, y - z)$ ,  $Y$  的边际 PDF 为  $l_Y(y) = \int_{-\infty}^{+\infty} f(z, y - z) dz$ 。

上例中, 若  $X_1, X_2$  相互独立, 则  $f(x_1, x_2) = f_1(x_1)f_2(x_2) \Rightarrow l_Y(y) = \int_{-\infty}^{+\infty} f_1(z)f_2(y - z) dz$ , 这称之为  $f_1$  和  $f_2$  的卷积, 记作  $f_1 * f_2$ 。

特别地, 若  $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2)$ 。

利用上述随机向量的函数的 PDF 求解方法, 可以得到所谓卡方分布 ( $\chi^2$ -分布)、 $t$ -分布和  $F$ -分布的 PDF。这些分布的表达式较为复杂, 在此不一一罗列。感兴趣的同学可以查阅资料, 简单了解一下它们与标准正态分布的联系。

## 第四章 随机变量的数字特征

### 4.1 期望

离散型和连续型随机变量的期望分别参见定义 2.6 和定义 2.11。

对于随机向量，期望自然推广定义为  $E((X_1, \dots, X_n)) = (E(X_1), \dots, E(X_n))$ 。

**命题 4.1.** 期望有如下性质：

1. 离散型和连续型随机向量的函数的期望  $E(g(X_1, \dots, X_n))$  分别等于

$$\sum_{x_i \in \{X_i(\omega) | \omega \in \Omega, \forall i \in \{1, \dots, n\}\}} g(x_1, \dots, x_n) f(x_1, \dots, x_n)$$

$$\text{和 } \int_{\mathbb{R}^n} g(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_1 \cdots dx_n,$$

其中  $g$  为可测函数， $f$  分别为联合 PMF 与联合 PDF

2.  $E(aX + bY) = aE(X) + bE(Y), \forall$  常数  $a, b \in \mathbb{R}$
3. 若  $X_1, \dots, X_n$  相互独立，则  $E(X_1 \cdots X_n) = E(X_1) \cdots E(X_n)$

### 4.2 分位数

**定义 4.1.** 设  $X$  为连续型随机变量，若  $P(X \leq m) = F(m) = 1/2$ ，则称  $m$  为  $X$  的中位数。

和均值一样，中位数也是随机变量集中趋势的一种刻画。中位数不一定唯一。

若  $m$  是连续型随机变量  $X$  的中位数，则  $P(X < m) = P(X > m) = 1/2$ 。

以下给出更一般的中位数定义。

**定义 4.2.** 对随机变量  $X$ ，若  $P(X < m) \leq 1/2$ ，且  $P(X > m) \leq 1 - 1/2 = 1/2$ ，则称  $m$  为  $X$  的中位数。

**例 4.1.** 设离散型随机变量  $X$  的分布表为

$X$	1	2	3	4
$P$	1/3	1/2	1/12	1/12

则其中位数为 2。

**定义 4.3.** 对随机变量  $X$ ,  $\forall \alpha \in (0, 1)$ , 若  $P(X < a) \leq \alpha$  且  $P(X > a) \leq 1 - \alpha$ , 则称  $a$  为  $X$  的 (下侧)  $\alpha$ -分位数。

上述定义的  $\alpha$ -分位数是不唯一的。为了唯一性, 我们考虑定义  $F^{-1}(\alpha) = \inf\{x | F(x) \geq \alpha\}$ 。

我们给出众数 (mode) 的方便定义:  $f(x)$  的最大值点, 其中  $f(x)$  为 PMF 或 PDF。由于 PDF 可在任意零测集上修改取值, 故这一定义并非严谨的。

## 4.3 方差

离散型和连续型随机变量的方差分别参见定义 2.6 和定义 2.11。

方差的意义: 若  $X$  为收益率, 则  $SD(X)$  称为波动率, 刻画了风险的大小。我们定义变异系数  $CV = \frac{SD(X)}{\mu}$ , 其中  $\mu = E(X) \neq 0$ 。

**命题 4.2.** 方差有如下性质:

1.  $\text{Var}(C) \equiv 0, C$  为常数
2.  $\text{Var}(CX) = C^2 \text{Var}(X)$
3.  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2E((X - E(X))(Y - E(Y)))$ , 且若  $X, Y$  独立, 则  $E((X - E(X))(Y - E(Y))) = 0$

## 4.4 协方差与相关系数

对随机变量  $X, Y$ , 设  $E(X) = \mu_1, E(Y) = \mu_2, \text{Var}(X) = \sigma_1^2, \text{Var}(Y) = \sigma_2^2$ 。

**定义 4.4.** 称  $X$  与  $Y$  的协方差  $\text{Cov}(X, Y) = E((X - \mu_1)(Y - \mu_2))$ 。

**命题 4.3.** 协方差有如下性质:

1.  $\text{Cov}(X, X) = \text{Var}(X)$
2.  $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
3.  $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$
4.  $\text{Cov}(aX_1 + bX_2 + c, Y) = a\text{Cov}(X_1, Y) + b\text{Cov}(X_2, Y), \forall$  常数  $a, b, c \in \mathbb{R}$

**定义 4.5.** 称  $X$  与  $Y$  的 (线性) 相关系数  $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_1 \sigma_2} = E\left(\frac{X - \mu_1}{\sigma_1} \frac{Y - \mu_2}{\sigma_2}\right)$ 。

若  $\text{Corr}(X, Y) = 0$ , 称  $X, Y$  不相关。

**定理 4.1.** 相关系数有如下性质:

1. 若  $X, Y$  相互独立, 则  $X, Y$  不相关 (反之未必成立)

2.  $|\text{Corr}(X, Y)| \leq 1$ , 且等号成立当且仅当  $\exists a, b, P(Y = aX + b) = 1$ , 即  $Y = aX + b, \text{a.s.}$

其中 a.s. 表示 “almost surely”。

为证明上述定理的 (2), 首先我们利用 Cauchy-Schwartz 不等式证明引理: 对随机变量  $U, V$ , 有  $E^2(UV) \leq E(U^2)E(V^2)$ , 且等号成立当且仅当  $\exists t_0 \in \mathbb{R}, P(V = t_0 U) = 1$ 。接下来令  $U = \frac{X - \mu_1}{\sigma_1}, V = \frac{Y - \mu_2}{\sigma_2}$ , 即得。

当  $\text{Corr}(X, Y) = \pm 1$ , 可以证明  $a = \pm \sigma_2 / \sigma_1$ 。

**例 4.2.**  $X \sim N(0, 1), Y = X^2$ , 则  $X$  与  $Y$  不相关, 但不独立。

**例 4.3.**  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则

$$\begin{aligned} & \text{Corr}(X, Y) \\ &= E\left(\frac{X - \mu_1}{\sigma_1} \frac{Y - \mu_2}{\sigma_2}\right) \\ &= \int_{\mathbb{R}^2} \frac{x - \mu_1}{\sigma_1} \frac{y - \mu_2}{\sigma_2} \frac{1}{2\pi\sigma_1\sigma_2} \frac{1}{\sqrt{1 - \rho^2}} e^{-\frac{1}{2(1 - \rho^2)}\left(\left(\frac{x - \mu_1}{\sigma_1}\right)^2 + \left(\frac{y - \mu_2}{\sigma_2}\right)^2 - 2\rho \frac{x - \mu_1}{\sigma_1} \frac{y - \mu_2}{\sigma_2}\right)} dx dy \end{aligned}$$

进行换元  $(u, v)^T = A\left(\frac{x - \mu_1}{\sigma_1}, \frac{y - \mu_2}{\sigma_2}\right)^T$ , 其中  $A$  的定义参见例 3.3, 则指数上的项化为  $-\frac{1}{2}(u^2 + v^2)$ , 这一步实质上是进行了二次型的标准化。后续过程留作习题, 最终计算结果为  $\text{Corr}(X, Y) = \rho$ 。

## 4.5 矩

**定义 4.6.** 对  $k = 1, 2, \dots$ , 称  $E((X - c)^k)$  为  $X$  关于  $c$  点的  $k$  阶矩。特别地,  $c = 0$  的情况下称为  $k$  阶原点矩,  $c = E(X)$  的情况下称为  $k$  阶中心矩。

根据定义可知,  $E(X)$  为 1 阶原点矩, 而 1 阶中心矩恒等于 0;  $\text{Var}(X) = E(X^2) - E^2(X)$  为 2 阶中心矩。

若  $E(X) = \mu, \text{SD}(X) = \sigma$ , 我们称  $E\left(\left(\frac{X - \mu}{\sigma}\right)^k\right) = \frac{E((X - \mu)^k)}{\sigma^k}$  为  $k$  阶标准矩。

1 阶标准矩恒等于 0, 2 阶标准矩恒等于 1, 3 阶标准矩称为  $X$  的偏度系数, 记作  $\text{Skew}(X)$ 。

**例 4.4.**  $X \sim N(0, 1)$ , 则  $\text{Skew}(X) = \int_{-\infty}^{+\infty} x^3 f(x) dx = 0$ , 其中  $f$  为  $X$  的 PDF。

我们称偏度系数  $< 0$  的分布为 “负偏” 或 “左偏”, 如图 4.1。

5 阶以上的奇数阶标准矩计算更复杂, 受噪声影响更大。


4 阶标准矩称为  $X$  的峰度系数, 记作  $\text{Kurt}(X)$ 。由于正态分布的峰度系数恒等于 3, 因此常定义超额峰度系数为  $\text{Kurt}(X) - 3$ 。

我们经常将  $\mu \pm \sigma$  以内的范围称为 “峰”, 范围在 “峰” 以外但在  $\mu \pm 2\sigma$  以内的范围称为 “肩”, 范围在 “肩” 以外的部分称为 “尾”。

通常, 峰度系数  $> 3$  表现为相对于正态分布 “尖峰厚尾”, 如图 4.2。



图 4.1: 负偏分布

图 4.2: “Leptokurtic” 一词的含义即峰度系数  $> 3$ 

## 4.6 矩母函数

**定义 4.7.** 记  $M_X(t) = E(e^{tX})$ , 若  $M_X(t)$  在  $t = 0$  的某邻域内存在, 则称其为  $X$  的矩母函数 (Moment Generating Function, MGF), 否则称  $X$  的矩母函数不存在。

**例 4.5.** 若  $X \sim \text{Exp}(\lambda)$ , 则  $M_X(t) = E(e^{tX}) = \int_0^{+\infty} e^{tx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - t}, t < \lambda$ 。

**例 4.6.** 若  $X \sim N(0, 1)$ , 则  $M_X(t) = E(e^{tX}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{tx} e^{-\frac{x^2}{2}} dx = e^{\frac{t^2}{2}}, t \in \mathbb{R}$ 。

**命题 4.4.** 矩母函数有如下性质:

1.  $M_X(0) \equiv 1$
2.  $Y = aX + b$ , 则  $M_Y(t) = E(e^{tY}) = E(e^{t(aX+b)}) = e^{tb} M_X(at)$

**例 4.7.** 若  $Y \sim N(\mu, \sigma^2)$ , 令  $Y = \sigma X + \mu$ , 则  $X \sim N(0, 1)$ , 故  $M_Y(t) = e^{\mu t} M_X(\sigma t) = e^{\mu t} e^{\frac{(\sigma t)^2}{2}} = e^{\frac{\sigma^2 t^2}{2} + \mu t}, t \in \mathbb{R}$ 。

矩母函数可以用于确定矩。

**定理 4.2.** 随机变量  $X$  的  $n$  阶 (原点) 矩与其矩母函数有如下关系:  $E(X^n) = M_X^{(n)}(0)$ 。

**证明.** 由 Taylor 展开有  $M_X(t) = \sum_{n=0}^{+\infty} M_X^{(n)}(0) \frac{t^n}{n!}$ , 又  $M_X(t) = E(e^{tX}) = E(\sum_{n=0}^{+\infty} X^n \frac{t^n}{n!}) = \sum_{n=0}^{+\infty} E(X^n) \frac{t^n}{n!}$ , 得到结论。  $\square$

**例 4.8.** 若  $X \sim N(0, 1)$ , 则  $M_X(t) = e^{\frac{t^2}{2}} = \sum_{n=0}^{+\infty} \frac{(\frac{t^2}{2})^n}{n!} = \sum_{n=0}^{+\infty} \frac{(2n)!}{2^n n!} \frac{t^{2n}}{(2n)!}$ , 因此我们得出  $E(X^{2n}) = \frac{(2n)!}{2^n n!}$ ,  $E(X^{2n+1}) \equiv 0$  ( $n = 0, 1, \dots$ )。

由此可以计算  $\text{Var}(X) = E(X^2) = 1$ ,  $\text{Kurt}(X) = E(X^4) = \frac{4!}{2^2 \cdot 2!} = 3$ 。

矩母函数还可以用于确定分布。

**定理 4.3.** 若存在  $a > 0$ , 使得  $M_X(t) = M_Y(t), \forall t \in (-a, a)$ , 则  $X, Y$  同分布。

**例 4.9.** 若随机变量  $X$  的矩母函数  $M_X(t) = \frac{1}{2}e^{-t} + \frac{1}{4} + \frac{1}{8}e^{4t} + \frac{1}{8}e^{5t}$ , 则  $X$  为离散型随机变量, 分布表为

$X$	-1	0	4	5
$P$	1/2	1/4	1/8	1/8

一般地, 若离散型随机变量  $X$  有 PMF  $P(X = k) = p_k$  ( $\sum_k p_k \equiv 1$ ), 则其 MGF 为  $M_X(t) = E(e^{tX}) = \sum_k e^{tk} p_k$ 。

注意, 各阶矩均相同的随机变量未必同分布。

**例 4.10.** 设连续型随机变量  $X_1$  和  $X_2$  的 PDF 分别为  $f_1(x) = \frac{1}{\sqrt{2\pi}x} e^{-\frac{(\log x)^2}{2}}, x > 0$  和  $f_2(x) = f_1(x)(1 + \sin(2\pi \log x)), x > 0$  ( $X_1$  服从对数正态分布), 则  $E(X_2^n) = E(X_1^n) + \int_0^{+\infty} x^n f_1(x) \sin(2\pi \log x) dx$ , 其中后一项通过换元  $y = \log x - n$  可以证明为 0, 即  $X_1$  和  $X_2$  同矩但不同分布。

下面我们运用矩母函数, 研究独立随机变量和的分布。

**定理 4.4.** 若随机变量  $X, Y$  独立,  $Z = X + Y$ , 则  $M_Z(t) = M_X(t)M_Y(t)$ 。

证明.  $M_Z(t) = E(e^{tZ}) = E(e^{t(X+Y)}) = E(e^{tX}e^{tY}) = M_X(t)M_Y(t)$ , 其中最后一个等号利用了独立性。□

推而广之, 若  $\{X_i\}_{i=1}^n$  相互独立,  $Z = X_1 + \dots + X_n$ , 则  $M_Z(t) = \prod_{i=1}^n M_{X_i}(t)$ 。

**例 4.11.** 若  $\{X_i\}_{i=1}^n$  相互独立且服从正态分布, 则  $X_1 + \dots + X_n$  也服从正态分布。

以  $n = 2$  为例说明。设  $X_i \sim N(\mu_i, \sigma_i^2)$  ( $i = 1, 2$ ), 则  $M_{X_1+X_2}(t) = M_{X_1}(t)M_{X_2}(t) = e^{\frac{\sigma_1^2 t^2}{2} + \mu_1 t} e^{\frac{\sigma_2^2 t^2}{2} + \mu_2 t} = e^{\frac{1}{2}(\sigma_1^2 + \sigma_2^2) + (\mu_1 + \mu_2)t}$ , 对应  $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$  的 MGF, 再由 MGF 确定分布可得结论。

定义随机向量  $(X_1, \dots, X_n)$  的 MGF 为  $M_{X_1, \dots, X_n}(t_1, \dots, t_n) = E(e^{t_1 X_1 + \dots + t_n X_n})$ 。

以下简介类似 MGF 的其他函数:

1. 概率母函数 (Probability Generating Function, PGF), 仅针对非负整数取值的离散型随机变量  $X$ , 设其 PMF 为  $P(X = k) = p_k$ , 则其 PGF 定义为  $E(t^X) = \sum_{k=0}^{+\infty} p_k t^k, t \in [-1, 1]$ , 或对于  $t \in (0, 1]$ , 等于  $E(e^{X \log t}) = M_X(\log t)$ 。
2. 特征函数, 定义为  $E(e^{itX})$ , 其中  $i^2 = -1$ 。

## 4.7 条件期望

我们定义条件期望  $E(Y|X \in A) = \begin{cases} \sum_i y_i P(Y = y_i | X \in A) \\ \int_{-\infty}^{+\infty} y f_{Y|X}(y|X \in A) dy \end{cases}$ , 两种定义分别针对  $Y$  为离散型和连续型随机变量。

进而, 我们定义  $E(Y|x) = E(Y|X = x) = \begin{cases} \sum_i y_i P(Y = y_i | X = x) \\ \int_{-\infty}^{+\infty} y f_{Y|X}(y|x) dy \end{cases}$ , 注意到这是一个  $x$

的函数, 记作  $h(x)$ 。将其作用在  $X$  上, 得到  $h(X) = E(Y|X)$ , 这是一个  $X$  的函数 (称为  $Y$  对  $X$  的回归函数), 因此是一个新的随机变量。

**例 4.12.**  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 则  $E(Y|x) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1)$ 。

**例 4.13.** 甲、乙两种同类产品, 平均使用寿命分别为 10 年和 15 年, 市场占有率分别为 60% 和 40%, 随机买一个, 则期望寿命是  $10 \times 60\% + 15 \times 40\% = 12$  年, 我们发现这个计算过程可以表示为  $E(Y) = E(Y|X = 1)P(X = 1) + E(Y|X = 2)P(X = 2) = h(1)P(X = 1) + h(2)P(X = 2) = E(h(X)) = E(E(Y|X))$ , 其中  $X = 1$  表示抽到甲产品,  $X = 0$  表示抽到乙产品,  $Y$  表示抽到的产品的寿命。

一般地, 我们有以下定理:

**定理 4.5.** (全期望公式)

对于随机向量  $(X, Y)$ , 有  $E(Y) = E(E(Y|X))$ 。

证明. 以连续型为例。设  $(X, Y)$  的联合 PDF 为  $f(x, y)$ , 有  $E(Y|x) = \int_{-\infty}^{+\infty} y f_{Y|X}(y|x) dy = \int_{-\infty}^{+\infty} y \frac{f(x, y)}{f_X(x)} dy$ , 故  $E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x, y) dx dy = \int_{-\infty}^{+\infty} E(Y|x) f_X(x) dx = E(E(Y|X))$ 。□

一般地, 对于可测函数  $g$ , 我们有  $E(g(X, Y)) = E(E(g(X, Y)|X))$ 。

**定理 4.6.** 对于随机向量  $(X, Y)$  和任意可测函数  $g: \mathbb{R} \rightarrow \mathbb{R}$ , 都有  $E((Y - g(X))^2) \geq E((Y - E(Y|X))^2)$ , 即条件期望是均方误差意义下的最优预测。

证明. 类比期望的性质  $E((Y - c)^2) \geq E((Y - E(Y))^2), \forall c \in \mathbb{R}$ , 我们有  $E((Y - g(X))^2|X) \geq E((Y - E(Y|X))^2|X), \forall g: \mathbb{R} \rightarrow \mathbb{R}$  可测, 两边对  $X$  求期望即得。  $\square$

我们经常用到最优线性预测, 即  $\min_{a,b} E((Y - (aX + b))^2)$ , 这种“均方意义上的最优”称之为最小二乘 (least square)。

**命题 4.5.** 记  $\hat{Y} = E(Y|X)$  为已知  $X$  的条件下对  $Y$  的最优估计,  $\tilde{Y}$  为估计误差  $\hat{Y} - Y$ , 则  $E(\tilde{Y}) = 0, E(\tilde{Y}\hat{Y}) = 0$ , 进而有  $\text{Cov}(\hat{Y}, \tilde{Y}) = 0, \text{Var}(Y) = \text{Var}(\hat{Y}) + \text{Var}(\tilde{Y})$ 。



## 第五章 不等式与极限定理

### 5.1 概率不等式

**定理 5.1.** (Markov 不等式)

若随机变量  $Y \geq 0$ , 则  $\forall a > 0$ , 有  $P(Y \geq a) \leq \frac{E(Y)}{a}$ 。

证明. 取示性变量  $I = \begin{cases} 1, & Y \geq a, \\ 0, & Y < a, \end{cases}$  则  $I \leq Y/a$ , 故  $P(Y \geq a) = E(I) \leq E(Y/a) = E(Y)/a$ 。

□

**定理 5.2.** (Chebyshev 不等式)

若随机变量  $Y$  的方差  $\text{Var}(Y)$  存在, 则  $\forall a > 0$  有  $P(|Y - E(Y)| \geq a) \leq \frac{\text{Var}(Y)}{a^2}$ 。

证明.  $P(|Y - E(Y)| \geq a) = P((Y - E(Y))^2 \geq a^2) \leq \frac{E((Y - E(Y))^2)}{a^2} = \frac{\text{Var}(Y)}{a^2}$ 。

□

这告诉我们, 如果  $\text{Var}(Y) = 0$ , 则  $P(Y = E(Y)) = 1$  (即 a.s.)。

**定理 5.3.** (Chernoff 不等式)

对于任意随机变量  $Y$ ,  $\forall a > 0, t > 0$ , 有  $P(Y \geq a) \leq \frac{E(e^{tY})}{e^{ta}}$ 。

证明.  $\forall t > 0, P(Y \geq a) = P(e^{tY} \geq e^{ta}) \leq \frac{E(e^{tY})}{e^{ta}}$ 。

□

**例 5.1.** 若  $X \sim N(0, 1)$ , 则

1. 根据 Markov 不等式,  $P(|X| \geq 3) \leq \frac{E(|X|)}{3} = \frac{1}{3}\sqrt{\frac{2}{\pi}} \approx 0.27$ ;
2. 根据 Chebyshev 不等式,  $P(|X| \geq 3) \leq \frac{\text{Var}(X)}{3^2} = \frac{1}{9} \approx 0.11$ ;
3. 根据 Chernoff 不等式,  $\forall t > 0, P(|X| \geq 3) = 2P(X \geq 3) \leq 2\frac{E(e^{tX})}{e^{3t}} = 2e^{\frac{t^2}{2}-3t}$ , 取最小值点  $t = 3$ , 得  $P(|X| \geq 3) \leq 2e^{-\frac{9}{2}} \approx 0.022$ ;
4. 根据经验法则,  $P(|X| \geq 3) \approx 0.003$ 。

## 5.2 大数定律

设随机变量  $X_1, \dots, X_n$  独立同分布, 均值  $E(X_i) = \mu$ , 方差  $\text{Var}(X_i) = \sigma^2 > 0$ , 则样本均值  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ , 其均值  $E(\bar{X}) = \mu$ , 方差  $\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \rightarrow 0 (n \rightarrow +\infty)$ 。

**定理 5.4.** (Khinchin 弱大数定律)

设随机变量  $X_1, \dots, X_n$  独立同分布, 均值  $E(X_i) = \mu$ , 方差  $\text{Var}(X_i) = \sigma^2 > 0$ , 则  $\forall \epsilon > 0$ , 有  $\lim_{n \rightarrow +\infty} P(|\bar{X} - \mu| \geq \epsilon) = 0$ , 或等价地,  $\lim_{n \rightarrow +\infty} P(|\bar{X} - \mu| < \epsilon) = 1$ 。

证明. 由 Chebyshev 不等式,  $P(|\bar{X} - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X})}{\epsilon^2} = \frac{\sigma^2}{n} \frac{1}{\epsilon^2} \rightarrow 0 (n \rightarrow +\infty)$ .  $\square$

$\forall \epsilon > 0, \forall \alpha > 0$ , 如果我们将  $\epsilon$  和  $(1 - \alpha)$  分别称为精度和置信度, 则根据 Khinchin 弱大数定律,  $\exists N \in \mathbb{N}^+$ , 当  $n \geq N$  时,  $P(|\bar{X} - \mu| < \epsilon) \geq 1 - \alpha$ , 即  $\bar{X}$  至少以概率  $(1 - \alpha)$  落在区间  $(\mu - \epsilon, \mu + \epsilon)$  内。

换句话说, 当样本量足够大时, 有很大的概率  $\bar{X} \approx \mu$ , 其中  $\mu$  为未知的总体均值。

我们将  $X_i \sim B(p)$  这一特例称之为 Bernoulli 大数定律。

通过更进一步的讨论可以证明, 上述定理中关于方差的条件可以去掉, 结论仍正确。

此外, 我们还有对 Khinchin 弱大数定律的若干推广, 如

1. 要求  $X_i$  两两不相关,  $\text{Var}(X_i)$  一致有界, 我们就得到了 Chebyshev 大数定律;
2. 要求  $\text{Var}(\bar{X}) \rightarrow 0 (n \rightarrow +\infty)$ , 我们就得到了 Markov 大数定律。

**定义 5.1.** 我们称  $Y_n$  依概率收敛于  $Y$ , 记作  $Y_n \xrightarrow{P} Y$ , 如果  $\forall \epsilon > 0$ , 有  $\lim_{n \rightarrow +\infty} P(|Y_n - Y| \geq \epsilon) = 0$ 。

用上述定义, 弱大数定律可以表述为  $\bar{X} \xrightarrow{P} \mu$ 。

**定理 5.5.** (Kolmogorov 强大数定律)

设随机变量  $X_1, \dots, X_n$  独立同分布, 均值  $E(X_i) = \mu$ , 则  $P(\lim_{n \rightarrow +\infty} \bar{X} = \mu) = 1$ 。

考虑  $X_i \sim B(p)$  的特殊情形, 则  $\bar{X}$  称之为频率, 由强大数定律,  $P(\lim_{n \rightarrow +\infty} \bar{X} = p) = 1$ , 这说明概率的频率解释是合理的。

**定义 5.2.** 我们称  $Y_n$  以概率 1 收敛于  $Y$ , 又称几乎必然收敛于  $Y$ , 记作  $Y_n \xrightarrow{\text{a.s.}} Y$ , 如果  $P(\lim_{n \rightarrow +\infty} Y_n = Y) = 1$ 。

用上述定义, 强大数定律可以表述为  $\bar{X} \xrightarrow{\text{a.s.}} \mu$ 。

**例 5.2.** (Monte Carlo 积分)

设我们要计算  $g(x) > 0$  在区间  $[a, b]$  上的定积分, 首先取一个适当的  $c > \sup\{g(x)|x \in [a, b]\}$ , 设  $(X_i, Y_i)$  独立且服从区域  $[a, b] \times [0, c]$  上的均匀分布, 记  $I_i = \begin{cases} 1, & Y_i \leq g(X_i), \\ 0, & Y_i > g(X_i), \end{cases}$  则  $I_i \sim B(p)$ ,

其中  $p = \frac{\int_a^b g(x)dx}{c(b-a)}$ , 于是  $\bar{I} = \frac{1}{n} \sum_{i=1}^n I_i \approx p$ , 从而  $\int_a^b g(x)dx \approx c(b-a)\bar{I}$ .

**例 5.3.** 我们通过一个例子来考察一下上面介绍的两种收敛性的区别。

设概率空间  $(\Omega, \mathcal{F}, P)$ , 其中  $\Omega = [0, 1]$ ,  $\omega$  在  $\Omega$  上均匀分布. 定义随机变量序列  $\forall \omega \in \Omega, Y_1(\omega) = \omega + I_{[0,1]}(\omega), Y_2(\omega) = \omega + I_{[0,1/2]}(\omega), Y_3(\omega) = \omega + I_{[1/2,1]}(\omega), Y_4(\omega) = \omega + I_{[0,1/3]}(\omega), Y_5(\omega) = \omega + I_{[1/3,2/3]}(\omega), Y_6(\omega) = \omega + I_{[2/3,1]}(\omega), \dots$ , 则  $Y_n(\omega)$  依概率收敛于  $Y(\omega) = \omega$ , 但不以概率 1 收敛于  $Y(\omega)$ , 因为  $\forall \omega_0 \in \Omega, Y_n(\omega_0)$  无极限。

## 5.3 中心极限定理

**定理 5.6.** 设随机变量  $X_1, \dots, X_n$  独立同分布, 均值  $E(X_i) = \mu$ , 方差  $\text{Var}(X_i) = \sigma^2 > 0$ , 则  $\forall x \in \mathbb{R}, \lim_{n \rightarrow +\infty} P\left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq x\right) = \Phi(x)$ , 其中  $\Phi(x)$  为标准正态分布的 CDF。或等价地,  $\lim_{n \rightarrow +\infty} P\left(\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = \Phi(x)$ 。

证明. 只对  $X_i$  的 MGF 存在的情形给出证明。

不失一般性, 假设  $\mu = 0, \sigma^2 = 1$ , 令  $M(t) = E(e^{tX_i})$ , 则  $M(0) = 1, M'(0) = 0, M''(0) = 1$ , 于是  $E(e^{t\frac{X_1 + \dots + X_n}{\sqrt{n}}}) = M^n\left(\frac{t}{\sqrt{n}}\right)$ , 而根据 Taylor 展开,  $M\left(\frac{t}{\sqrt{n}}\right) = 1 + 0 + \frac{1}{2}\left(\frac{t}{\sqrt{n}}\right)^2 + o\left(\frac{t^2}{n}\right)$ , 故  $E(e^{t\frac{X_1 + \dots + X_n}{\sqrt{n}}}) = (1 + \frac{t^2}{2n} + o(\frac{t^2}{n}))^n \rightarrow e^{t^2/2} (n \rightarrow +\infty)$ , 此为  $N(0, 1)$  的 MGF, 这说明  $\frac{X_1 + \dots + X_n}{\sqrt{n}}$  的分布趋近于  $N(0, 1)$ 。□

上述定理通常称为 Lindeberg-Lévy CLT, 可推广至不同分布的情形。

如果将定理中的  $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$  理解为标准化的过程, 则不难得出  $\bar{X}$  近似服从  $N(\mu, \frac{\sigma^2}{n})$ ,  $X_1 + \dots + X_n$  近似服从  $N(n\mu, n\sigma^2)$ 。

**例 5.4.** (De Moivre-Laplace CLT)

设  $X_i \sim B(p)$ , 则  $\sum_{i=1}^n X_i \sim B(n, p)$ , 当  $n$  充分大时, 可以近似地认为  $\sum_{i=1}^n X_i \sim N(np, np(1-p))$ , 于是我们可近似计算  $P(t_1 \leq \sum_{i=1}^n X_i \leq t_2) = P\left(\frac{t_1 - np}{\sqrt{np(1-p)}} \leq \frac{\sum_{i=1}^n X_i - np}{\sqrt{np(1-p)}} \leq \frac{t_2 - np}{\sqrt{np(1-p)}}\right) \approx \Phi(y_2) - \Phi(y_1)$ , 其中  $y_1 = \frac{t_1 - np - \frac{1}{2}}{\sqrt{np(1-p)}}, y_2 = \frac{t_2 - np + \frac{1}{2}}{\sqrt{np(1-p)}}$ , 其中  $\frac{1}{2}$  是连续性修正项。

**定义 5.3.** (依分布收敛)

我们称  $Y_n$  依分布收敛于  $Y$ , 记作  $Y_n \xrightarrow{d} Y$ , 如果  $\lim_{n \rightarrow +\infty} F_{Y_n}(x) = F_Y(x), \forall x \in \mathbb{R}$ 。

用上述定义, CLT 可以表述为  $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \xrightarrow{d} Z$ , 其中  $Z \sim N(0,1)$ , 或简记为  $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \rightarrow N(0,1)$ 。

**例 5.5.** (选举问题)

设  $p$  为选民真实支持度 (未知), 随机抽样调查  $n$  人 (假设  $n$  远远小于总人数  $N$ , 可以近似有放回抽样), 样本支持比例  $P_n = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$ , 其中  $X_i \sim B(p)$  且独立, 表示第  $i$  个人是否支持。

设置精度  $\epsilon = 0.03$ , 置信度  $1-\alpha = 95\%$ , 则至少需要  $n$  为多少, 才能保证  $P(|P_n - p| < \epsilon) \geq 1-\alpha$ ? 根据 CLT, 我们有  $P(|P_n - p| \geq \epsilon) \approx 2 \left( 1 - \Phi\left(\frac{\epsilon}{\sqrt{p(1-p)/n}}\right) \right) \leq \alpha$ , 于是  $n \geq \frac{z_{\alpha/2}^2 p(1-p)}{\epsilon^2}$ , 其中  $z_{\alpha/2}$  为标准正态分布的上  $\alpha/2$  分位数, 代入最大值点  $p = \frac{1}{2}$ , 我们得到  $n \geq \frac{z_{\alpha/2}^2}{4} \epsilon^2$ , 代入  $\epsilon = 0.03, \alpha = 0.05$ , 得到  $n \geq 1068$ 。这一结果与  $N$  无关!

## 第二部分

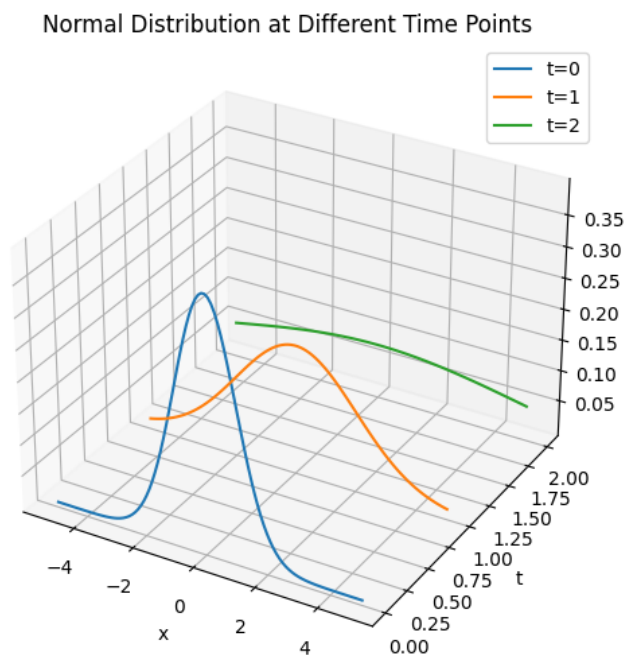
## 随机过程

# 随机过程引言

**定义.** 给定一个概率空间  $(\Omega, \mathcal{F}, P)$ , 若对于某个集合  $T$  (称之为指标集),  $\forall t \in T$ , 都有一个随机变量  $X_t$ , 则称  $\{X_t\}_{t \in T}$  为一个随机过程 (Stochastic Process), 也记作  $\{X_t, t \in T\}$ . 称  $X_t$  为该随机过程在  $t$  时刻的状态, 有时也记作  $X(t)$ , 其取值集合  $S$  称为状态空间, 即  $\forall t \in T, \forall \omega \in \Omega, X_t(\omega) \in S$ .  $\forall \omega_0 \in \Omega$ , 称  $\{X_t(\omega_0), t \in T\}$  为该随机过程的一条样本轨道 (Sample Path)。

随机变量是  $\Omega$  上的函数, 而随机过程是一列随机变量, 因此  $X_t(\omega)$  可以视为  $t, \omega$  的函数。

**例.** 设  $X_0, U$  独立且均服从  $N(0, 1)$ , 令  $X_t = X_0 + tU$ , 则  $\{X_t, t \in \mathbb{R}\}$  是一个随机过程,  $\forall t \in \mathbb{R}, X_t \sim N(0, t^2 + 1)$ , 如下图所示。



$\{X_t, t \in \mathbb{R}\}$  的分布

**例.** 设  $\{Y_i\}_{i=1}^{\infty}$  独立同分布, 且  $P(Y_i = 1) = P(Y_i = -1) = \frac{1}{2}$ , 令  $Y_0 = 0, X_n = \sum_{i=0}^n Y_i$ , 则  $\{X_n, n \in \mathbb{N}\}$  是一个随机过程, 称之为二维随机游走 (Random Walk)。

---

如果一个随机过程的  $T$  是离散的，常称之为时间序列 (Time Series)。而如果  $S$  是离散的，有时用链 (Chain) 来称呼这样的随机过程。

**定义.** 若  $\forall n, \forall t_1 < t_2 < \cdots < t_n (t_1, \cdots, t_n \in T)$ , 满足  $X_{t_2} - X_{t_1}, X_{t_3} - X_{t_2}, \cdots, X_{t_n} - X_{t_{n-1}}$  相互独立, 则称  $\{X_t, t \in T\}$  为独立增量过程。若  $T$  中包含最小指标  $t_0$ , 则要求  $X_{t_0}, X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \cdots, X_{t_n} - X_{t_{n-1}}$  相互独立。

**定义.** 若  $\forall t \in T, \forall \tau$  s.t.  $t + \tau \in T$ , 满足  $X_{t+\tau} - X_t$  只依赖  $\tau$  (不依赖  $t$ ), 则称  $\{X_t, t \in T\}$  为平稳增量过程。

一个随机过程  $\{X_t, t \in T\}$  是平稳增量过程, 等价于  $\forall t_1, t_2 \in T, \forall \tau$  s.t.  $t_i + \tau \in T (i = 1, 2)$ , 总有  $X_{t_1+\tau} - X_{t_1}$  与  $X_{t_2+\tau} - X_{t_2}$  同分布。

# 第六章 Poisson 过程

## 6.1 基本概念

首先简单介绍一下 Bernoulli 过程。

**定义 6.1.** 设  $T = \mathbb{N}^*$ ,  $\{X_n\}_{n=1}^\infty$  是一列独立同分布的随机变量, 且  $P(X_n = 1) = p, P(X_n = 0) = 1 - p$ , 则称  $\{X_n\}_{n=1}^\infty$  为参数为  $p$  的 Bernoulli 过程。

定义中提到的  $\{X_n\}_{n=1}^\infty$  相互独立, 指的是  $\forall n \in \mathbb{N}^*$ , 都有  $X_1, \dots, X_n$  相互独立。

如果在每个离散时刻  $n$ , 事件  $X_n = 1$  即“第  $n$  次试验成功”对应的是该时刻有一个顾客到达某商店, 则 Bernoulli 过程可以理解成一种到达过程。本章的主要内容 Poisson 过程也是一种到达过程。

**定义 6.2.** 称一个随机过程  $\{N(t), t \geq 0\}$  为计数过程, 若满足:

1.  $N(0) = 0$ , 且  $N(t) \in \mathbb{N}$
2.  $\forall t > s \geq 0, N(t) \geq N(s)$
3.  $N(t) - N(s)$  为  $(s, t]$  时间内发生的事件数

**定义 6.3.** 称一个计数过程  $\{N(t), t \geq 0\}$  为 Poisson 过程, 若满足:

1.  $N(0) = 0$
2.  $\{N(t), t \geq 0\}$  有平稳增量和独立增量
3.  $\exists \lambda > 0$ , 当  $h \rightarrow 0$  时,  $P(N(h) = 1) = \lambda h + o(h)$
4. 当  $h \rightarrow 0$  时,  $P(N(h) \geq 2) = o(h)$

利用平稳增量性可知,  $\forall t \geq 0, P(N(t+h) - N(t) = 1) = \lambda h + o(h), P(N(t+h) - N(t) \geq 2) = o(h)$ 。

考虑  $[0, t]$  时间段, 将其分成  $n$  个长度为  $\frac{t}{n}$  的子区间, 当  $n \gg 1$  时, 每个小区间上发生 2 次及以上事件的概率趋于 0, 而发生 1 次事件的概率  $p \approx \lambda \frac{t}{n}$ , 因此近似有  $N(t) \sim B(n, p)$ , 而我们知道当  $n \rightarrow \infty$  时,  $B(n, p)$  会趋向于 Poisson 分布, 即  $N(t) \sim P(\lambda t)$ 。稍后我们将严格证明这一结论。



称  $\lambda$  为 Poisson 过程的强度或到达率。

**命题 6.1.** 若  $\{N(t), t \geq 0\}$  是 Poisson 过程, 则  $\forall t \geq 0, N(t) \sim P(\lambda t)$ 。

证明. 记  $P_n(t) = P(N(t) = n)$  ( $n \in \mathbb{N}$ ), 则  $P_0(t+h) = P(N(t+h) = 0) = P(N(t+h) - N(t) = 0, N(t) = 0) = P(N(t+h) - N(t) = 0)P(N(t) = 0) = (1 - \lambda h + o(h))P_0(t)$ , 即  $\frac{P_0(t+h)-P_0(t)}{h} = -\lambda P_0(t) + \frac{o(h)}{h}$ 。当  $h \rightarrow 0$  时,  $\frac{o(h)}{h} \rightarrow 0$ , 因此  $\frac{P_0(t+h)-P_0(t)}{h} \rightarrow -\lambda P_0(t)$ , 即  $P'_0(t) = -\lambda P_0(t)$ , 由边界条件  $P_0(0) = P(N(0) = 0) = 1$  解得  $P_0(t) = e^{-\lambda t} = \frac{(\lambda t)^0}{0!} e^{-\lambda t}$ 。同理,

$$\begin{aligned}
 & P_n(t+h) \\
 &= P(N(t+h) = n) \\
 &= P(N(t+h) - N(t) = 0, N(t) = n) + P(N(t+h) - N(t) = 1, N(t) = n-1) \\
 &+ P(N(t+h) - N(t) \geq 2, N(t+h) = n) \\
 &= P(N(t+h) - N(t) = 0)P(N(t) = n) + P(N(t+h) - N(t) = 1)P(N(t) = n-1) \\
 &+ P(N(t+h) - N(t) \geq 2, N(t+h) = n) \\
 &= P(N(h) = 0)P_n(t) + P(N(h) = 1)P_{n-1}(t) + o(h) \\
 &(\because P(N(t+h) - N(t) \geq 2, N(t+h) = n) \leq P(N(t+h) - N(t) \geq 2) \\
 &= P(N(h) \geq 2) = o(h)) \\
 &= (1 - \lambda h + o(h))P_n(t) + (\lambda h + o(h))P_{n-1}(t) + o(h) \\
 &= P_n(t) + \lambda h(P_{n-1}(t) - P_n(t)) + o(h)
 \end{aligned}$$

□